RAG 知识库文档解析测试

本文件介绍 RAG 的基本流程、示例参数和检索评估指标，包含中文正文、表格、Word 原生公式和图片，可用于文档解析实验。

一 RAG 基本流程

RAG 即检索增强生成。系统先根据用户问题检索相关资料，再将问题和资料一起提供给大模型，生成有资料依据的回答。

文档入库时，需要读取和切分内容，再通过 Embedding 模型生成向量。查询与文档应使用相同的向量模型，并保留来源文件、章节等元数据。

二 示例参数

配置项	示例值	说明
chunk_size	800 字符	每个片段的目标最大长度
chunk_overlap	100 字符	相邻片段的重叠长度
top_k	5	本次检索返回的候选片段数

三 检索评估公式

前 k 条检索结果中，如果有 r 条与问题相关，查准率 p 可按下方公式计算。该指标用于评估检索结果的相关性。

$$p = \frac{r}{k}$$

计算示例：返回 5 条结果，其中 4 条相关，则本次 Precision@5 为 80%。示例参数需要结合实际文档和检索效果调整。

四 知识库入库流程

下图展示知识库入库的四个步骤，可用于检查图片提取、图片描述或 OCR 的效果。

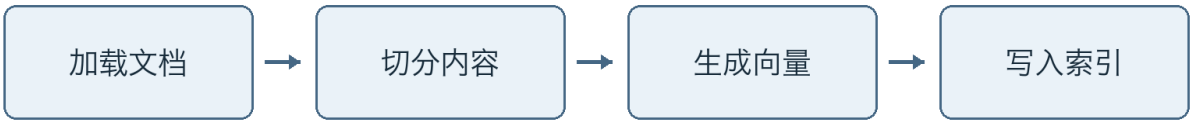


图 1 RAG 知识库入库流程示意图